

تحليل استكشاف البيانات والرسوم البيانية

Data Exploration & Visualization Analysis

مجموعة بيانات أداء الطلاب الأكاديمية

Student Academic Performance Dataset

يوفر هذا الدفتر تحليلاً إحصائياً شاملاً وتمثيلات بصرية لمقاييس أداء الطلاب الرئيسية والأنماط السلوكية ومؤشرات الرفاهية.

This notebook provides comprehensive statistical analysis and visual representations of key student performance metrics, behavioral patterns, and well-being indicators.

الإعدادات والمكتبات

Setup & Libraries

```
In [19]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats

# تعيين نمط الرسوم البيانية
# Set style for all visualizations
sns.set_style('whitegrid')
plt.rcParams['figure.figsize'] = (12, 6)
plt.rcParams['font.size'] = 11

# تحميل مجموعة البيانات الخاصة بك
# Load your dataset
df = pd.read_csv(
    'C:/Users/ayman/OneDrive/Desktop/data-analysis-project/data/raw/AI_SocialMed
) # استبدل بالمسار الفعلي / Replace with actual path
print(f'شكل مجموعة البيانات / Dataset shape: {df.shape}')
print(f'الأعمدة / Columns: {df.columns.tolist()}')
```

Dataset shape: (15000, 14)
Columns: ['Student_ID', 'Age', 'Gender', 'Education_Level', 'Daily_Social_Media_Hours', 'Daily_AI_Tool_Usage_Hours', 'Sleep_Hours', 'Physical_Activity_Hours', 'Mental_Health_Score', 'Physical_Health_Score', 'Social_Isolation_Score', 'Burnout_Level', 'Academic_Performance_Score', 'Academic_Failure_Risk']

القسم 1: تحليل الأداء الأكاديمي

Section 1: Academic Performance Analysis

رسم الصندوق لدرجة الأداء الأكاديمي

Box Plot of Academic Performance Score

نظرة عامة على الشكل يعرض رسم الصندوق هذا التوزيع والاتجاه المركزي والتشتت والقيم الشاذة عبر مجموعة الطلاب Academic_Performance_Score في الطرف السفلي للمتغير المستمر المحللة.

Figure Overview This box plot displays the distribution, central tendency, dispersion, and lower-tail outliers for the continuous variable Academic_Performance_Score across the analyzed student cohort.

الاتجاهات الإحصائية الرئيسية والنتائج

- تتمركز الدرجة الوسيطة حول 78.5 تقريباً، مع نطاق (IQR) الاتجاه المركزي ونطاق الربيعي مما يشير إلى إنجاز أكاديمي عالي جداً، (Q₃) إلى 86.5 (Q₁) يمتد من حوالي 70.5 (IQR) الربيعي عبر 50% الأوسط من الطلاب.
- الانحراف الأيسر والقيم الشاذة: يظهر التوزيع انحرافاً يساراً واضحاً. بينما تمتد الدرجات بسلاسة إلى الحد الأقصى 100، ينتهي الخط السفلي حول 46، مع مجموعة كبيرة من القيم الشاذة منخفضة الأداء تمتد إلى حوالي 24.

Key Findings & Statistical Trends

- Central Tendency & IQR:** The median score centers around approximately 78.5, with the Interquartile Range (IQR) spanning from roughly 70.5 (Q₁) to 86.5 (Q₃), indicating high overall academic achievement across the middle 50% of students.
- Negative Skewness & Outliers:** The distribution demonstrates a distinct left (negative) skew. While scores extend smoothly to an upper maximum of 100, the lower whisker terminates around 46, with a significant cluster of low-performing outliers stretching down to roughly 24.

الرؤى المستخلصة من البيانات

- تقسيم المخاطر الثنائي: يظهر معظم الطلاب كفاءة أكاديمية قوية، لكن الذيل المستمر من القيم الشاذة يسلط الضوء على مجموعة فرعية ضعيفة تواجه ضعفاً أكاديمياً شديداً.
- ارتباط محتمل بالضغط/الإرهاق: غالباً ما ترتبط الدرجات المنخفضة جداً بقوة بالإجهاد النفسي الحاد والإرهاق غير المُدار أو الغياب المطول.

Data Insights

- Bimodal Risk Division:** Most students demonstrate strong academic competency, but the persistent tail of low-value outliers highlights a vulnerable subgroup experiencing severe academic underperformance.
- Potential Correlation with Stress/Burnout:** Extreme low-end scores often correlate strongly with acute mental health strain, unmanaged burnout, or prolonged

absenteeism, signaling a disconnect between general institutional outcomes and high-risk individuals.

الخطوات العملية القابلة للتنفيذ

- **حدود التدخل المبكر الموجهة:** إنشاء مشغل المخاطر الآلي للطلاب الذين يسقطون تحت حد الخط السفلي (~46) لتوفير الدعم الأكاديمي والنفسي الفوري.
- **هندسة الميزات للنمذجة التنبؤية:** تطبيق تقنيات القياس القوي أو التحويل لتخفيف تأثير القيم الشاذة على نماذج الانحدار الخطي.

Actionable Takeaways

- **Targeted Early-Intervention Thresholds:** Establish an automated risk trigger for students falling below the lower whisker boundary (~46) to provide immediate academic tutoring and mental health support.
- **Feature Engineering for Predictive Modeling:** Consider applying robust scaling or transformation techniques (e.g., Winsorization or log-based adjustments) to mitigate the influence of extreme low outliers during linear model training.

```
In [20]: # إنشاء رسم الصندوق لدرجة الأداء الأكاديمي
# Create box plot for Academic Performance Score
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, y='Academic_Performance_Score', ax=ax, palette='Set2')
ax.set_title('توزيع درجة الأداء الأكاديمي\nDistribution of Academic Performance')
ax.set_ylabel('الدرجة / Score', fontsize=12)
ax.grid(axis='y', alpha=0.3)

# إضافة التعليقات الإحصائية
# Add statistical annotations
q1 = df['Academic_Performance_Score'].quantile(0.25)
q3 = df['Academic_Performance_Score'].quantile(0.75)
median = df['Academic_Performance_Score'].median()
iqr = q3 - q1

stats_text = f'الوسيط / Median: {median:.2f}\nQ1: {q1:.2f}\nQ3: {q3:.2f}\nIQR: {iqr:.2f}'
ax.text(0.98, 0.97, stats_text, transform=ax.transAxes,
        fontsize=10, verticalalignment='top', horizontalalignment='right',
        bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.5))

plt.tight_layout()
plt.savefig('../reports/figures/boxplot_Academic_Performance_Score.png', dpi=300)
plt.show()

print('إحصائيات درجة الأداء الأكاديمي / Academic Performance Score Statistics:')
print(f'المتوسط / Mean: {df["Academic_Performance_Score"].mean():.2f}')
print(f'الوسيط / Median: {median:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Academic_Performance_Score"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Academic_Performance_Score"].min():.2f}')
print(f'الحد الأقصى / Max: {df["Academic_Performance_Score"].max():.2f}')
```

C:\Users\ayman\AppData\Local\Temp\ipykernel_23652\2460570247.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v 0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df, y='Academic_Performance_Score', ax=ax, palette='Set2')
```



إحصائيات درجة الأداء الأكاديمي / Academic Performance Score Statistics:

المتوسط / Mean: 78.31

الوسيط / Median: 78.59

الانحراف المعياري / Std Dev: 11.54

الحد الأدنى / Min: 23.99

الحد الأقصى / Max: 99.98

القسم 2: تحليل الخصائص الديموغرافية

Section 2: Demographic Analysis

رسم الصندوق للعمر

Box Plot of Age

نظرة عامة على الشكل يصور رسم الصندوق هذا التوزيع الديموغرافي الشامل والاتجاهات المركزية وانتشار أعمار الطلاب في مجموعة البيانات.

Figure Overview This box plot depicts the overall demographic distribution, central tendencies, and spread of student ages within the dataset.

الاتجاهات الإحصائية الرئيسية والنتائج

- **التوزيع المتماثل:** يقع متوسط العمر بدقة عند 19 سنة، مما يقسم مجموعة البيانات إلى نصفين متوازنين.
- **نطاق ربيعي واسع (IQR):** 16 (Q₁) و 22 (Q₃) تمتد 50% الأوسط من السكان بين 16 و 22 سنة من (Q₃) و 22 (Q₁)، مما يعكس إجمالي 6 سنوات IQR العمر، مما يعكس
- **النطاق الكامل وغياب القيم الشاذة:** تتراوح مجموعة البيانات بشكل مستمر من حد أدنى 13 إلى حد أقصى 25 سنة، محدودة بنظافة من قبل الخطوط بدون قيم شاذة إحصائية.

Key Findings & Statistical Trends

- **Symmetric Distribution:** The median age sits precisely at 19 years old, dividing the dataset into balanced upper and lower halves.
- **Broad Interquartile Range (IQR):** The middle 50% of the population spans between 16 (Q₁) and 22 (Q₃) years of age, reflecting an overall IQR of 6 years.
- **Full Range & Absence of Outliers:** The dataset ranges continuously from a minimum of 13 to a maximum of 25 years old, bounded cleanly by the whiskers without any statistical outliers beyond the 1.5 times textIQR limits.

الرؤى المستخلصة من البيانات

- **مراحل تطورية متنوعة:** يشير نطاق العمر الواسع إلى مجموعة بيانات تسجل المراهقين والبالغين في سن الجامعة التقليديين.
- **محفزات الضغط المختلفة:** من المحتمل أن تختلف العوامل البيئية المؤثرة على الأداء الأكاديمي والرفاهية النفسية بشكل كبير عبر فئات العمر.

Data Insights

- **Diverse Developmental Stages:** The broad age band indicates a dataset capturing both high school/secondary-level teenagers (13–17) and traditional university-aged adults (18–25).
- **Differential Stressors:** Environmental factors impacting academic performance and mental wellness likely vary significantly across age brackets (e.g., parental dependencies for younger students versus financial/career independence for older cohorts).

الخطوات العملية القابلة للتنفيذ

- **هندسة الميزات المقسمة حسب العمر:** تقسيم مجموعة البيانات إلى مجموعات عمرية متميزة (مثل المراهقون $17 \geq$ مقابل البالغون الشباب $18 \leq$).
- **لا توجد حاجة لقص القيم الشاذة:** يُظهر المقياس حدوداً نظيفة دون ضجيج قصوي.

Actionable Takeaways

- **Age-Stratified Feature Engineering:** Segment the dataset into distinct age cohorts (e.g., Adolescents $le17$ vs. Young Adults).

ge18

) during modeling to evaluate whether stress predictors and failure risk factors interact differently across developmental stages.

- **No Outlier Truncation Needed:** The metric exhibits clean boundaries without extreme noise, requiring no data removal or capping before downstream regression or classification tasks.

```
In [21]: # إنشاء رسم الصندوق للعمر /
# Create box plot for Age
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, y='Age', ax=ax, palette='Set1')
ax.set_title('توزيع عمر الطالب\nDistribution of Student Age', fontsize=14, font
ax.set_ylabel('العمر بالسنوات / Age (years)', fontsize=12)
ax.grid(axis='y', alpha=0.3)

# إضافة التعليقات الإحصائية /
# Add statistical annotations
q1_age = df['Age'].quantile(0.25)
q3_age = df['Age'].quantile(0.75)
median_age = df['Age'].median()
iqr_age = q3_age - q1_age

stats_text = f'الوسيط / Median: {median_age:.1f}\\nQ1: {q1_age:.1f}\\nQ3: {q3_age:.1f}'
ax.text(0.98, 0.97, stats_text, transform=ax.transAxes,
        fontsize=10, verticalalignment='top', horizontalalignment='right',
        bbox=dict(boxstyle='round', facecolor='lightblue', alpha=0.5))


plt.tight_layout()
plt.savefig('../reports/figures/boxplot_Age.png', dpi=300, bbox_inches='tight')
plt.show()

print('إحصائيات العمر / Age Statistics:')
print(f'المتوسط / Mean: {df["Age"].mean():.2f}')
print(f'الوسيط / Median: {median_age:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Age"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Age"].min():.0f}')
print(f'الحد الأقصى / Max: {df["Age"].max():.0f}')
```

C:\Users\ayman\AppData\Local\Temp\ipykernel_23652\73247022.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v 0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df, y='Age', ax=ax, palette='Set1')
```



إحصائيات العمر / Age Statistics:

المتوسط / Mean: 19.04

الوسيط / Median: 19.00

الانحراف المعياري / Std Dev: 3.77

الحد الأدنى / Min: 13

الحد الأقصى / Max: 25

القسم 3: تحليل استخدام التكنولوجيا

Section 3: Technology Usage Analysis

رسم الصندوق لساعات استخدام أدوات الذكاء الاصطناعي اليومي

Box Plot of Daily AI Tool Usage Hours

نظرة عامة على الشكل يعرض رسم الصندوق هذا التوزيع الإحصائي والاتجاه المركزي والتشتت والقيم الشاذة في الطرف العلوي لميزة استخدام أدوات الذكاء الاصطناعي اليومي عبر السكان المستطلعين.

Figure Overview This box plot displays the statistical distribution, central tendency, dispersion, and upper-tail outliers for the continuous feature

Daily_AI_Tool_Usage_Hours across the surveyed student population.

الاتجاهات الإحصائية الرئيسية والنتائج

- يقع متوسط الاستخدام اليومي حول 2.5 ساعة، مع **(IQR) الاتجاه المركزي ونطاق الربيعي** (Q₃) إلى 3.7 ساعات (Q₁) يمتد من حوالي 1.3 ساعة IQR نطاق.
- الانحراف الأيمن والذيل الثقيل:** يُظهر التوزيع انحرافاً أيمن قوي. بينما ينعلق الخط العلوي الرئيسي حول 7.4 ساعات، يمتد تدفق مستمر من القيم الشاذة بقوة.

Key Findings & Statistical Trends

- **Central Tendency & IQR:** The median daily usage sits at approximately 2.5 hours, with the Interquartile Range (IQR) spanning from roughly 1.3 hours (Q_1) to 3.7 hours (Q_3).
- **Right Skewness & Heavy Tail:** The distribution exhibits a strong right (positive) skew. While the main upper whisker caps around 7.4 hours, a continuous stream of upper outliers extends beyond this boundary, reaching up to nearly 9.5 hours daily.

الرؤى المستخلصة من البيانات

- **ديناميات الاعتماد الثنائي:** يحتفظ معظم الطلاب بتفاعل معتدل مع أدوات الذكاء الاصطناعي (1-4 ساعات/يوم)، ولكن مجموعة فرعية متميزة تنفق مدة قصوى الإفراط في الاعتماد ومخاطر الإرهاق: قد ترتبط ساعات الاستخدام المرتفعة بشكل غير عادي بالإجهاد الأكاديمي والصعوبات في إدارة الوقت.

Data Insights

- **Bimodal Reliance Dynamics:** Most students maintain moderate interaction with AI tools (1–4 hours/day), integrating them as supplementary study aids. However, a distinct sub-cohort spends extreme duration (≥ 7.5 hours) relying on AI tools.
- **Over-reliance & Burnout Risk:** Unusually high daily usage hours may correlate with academic strain, time-management difficulties, or increased mental burnout, where students utilize AI to offset heavy course loads or deadline pressure.

الخطوات العملية القابلة للتنفيذ

- **تقييم العلاقات غير الخطية:** حلل ما إذا كانت ساعات الاستخدام القصوى (≤ 7.5) ترتبط بأداء أكاديمي منخفض أو درجات ضائقة عقلية أعلى.
- **تحويل القيم الشاذة للنماذج الخطية:** تطبيق تحويل لوغاريتمي أو تحديد سقف عند المئين 99 لتحديد تأثير القيم الشاذة الثقيلة.

Actionable Takeaways

- **Evaluate Non-Linear Relationships:** Analyze whether extreme usage hours (≥ 7.5) correlate with lower academic performance or higher mental distress scores using non-linear modeling or binning techniques.
- **Cap or Transform Outliers for Linear Models:** Apply logarithmic transformation or capping at the 99^{textth} percentile to limit the leverage of heavy upper outliers in sensitive machine learning algorithms.

```
In [22]: # إنشاء رسم الصندوق لساعات استخدام أدوات الذكاء الاصطناعي اليومي
# Create box plot for Daily AI Tool Usage Hours
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, y='Daily_AI_Tool_Usage_Hours', ax=ax, palette='viridis')
ax.set_title('توزيع ساعات استخدام أدوات الذكاء الاصطناعي اليومي\nDistribution')
ax.set_ylabel('الساعات / Hours per day', fontsize=12)
```

```

ax.grid(axis='y', alpha=0.3)

# إضافة التعليقات الإحصائية
# Add statistical annotations
q1_ai = df['Daily_AI_Tool_Usage_Hours'].quantile(0.25)
q3_ai = df['Daily_AI_Tool_Usage_Hours'].quantile(0.75)
median_ai = df['Daily_AI_Tool_Usage_Hours'].median()
iqr_ai = q3_ai - q1_ai

stats_text = f'الوسيط / Median: {median_ai:.2f}\\nQ1: {q1_ai:.2f}\\nQ3: {q3_ai:.2f}\\nIQR: {iqr_ai:.2f}'
ax.text(0.98, 0.97, stats_text, transform=ax.transAxes,
        fontsize=10, verticalalignment='top', horizontalalignment='right',
        bbox=dict(boxstyle='round', facecolor='lightgreen', alpha=0.5))

plt.tight_layout()
plt.savefig('../reports/figures/boxplot_Daily_AI_Tool_Usage_Hours.png', dpi=300,
            plt.show())


print('إحصائيات استخدام أدوات الذكاء الاصطناعي اليومي / Daily AI Tool Usage Statistics:')
print(f'المتوسط / Mean: {df["Daily_AI_Tool_Usage_Hours"].mean():.2f}')
print(f'الوسيط / Median: {median_ai:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Daily_AI_Tool_Usage_Hours"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Daily_AI_Tool_Usage_Hours"].min():.2f}')
print(f'الحد الأقصى / Max: {df["Daily_AI_Tool_Usage_Hours"].max():.2f}')

```

C:\Users\ayman\AppData\Local\Temp\ipykernel_23652\2721894021.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df, y='Daily_AI_Tool_Usage_Hours', ax=ax, palette='viridis')
```



إحصائيات استخدام أدوات الذكاء الاصطناعي اليومي / Daily AI Tool Usage Statistics:

المتوسط / Mean: 2.58
الوسيط / Median: 2.51
الانحراف المعياري / Std Dev: 1.68
الحد الأدنى / Min: 0.00
الحد الأقصى / Max: 9.50

رسم الصندوق لساعات وسائل التواصل الاجتماعي اليومية

Box Plot of Daily Social Media Hours

نظرة عامة على الشكل يقيّم رسم الصندوق هذا التوزيع الإحصائي والاتجاه المركزي والتباين والقيم القصوى لمتغير ساعات وسائل التواصل الاجتماعي اليومية عبر مجموعة الطلاب.

Figure Overview This box plot evaluates the statistical distribution, central tendency, variance, and extreme values for the continuous variable `Daily_Social_Media_Hours` across the student cohort.

الاتجاهات الإحصائية الرئيسية والنتائج

- يقع متوسط استخدام وسائل التواصل الاجتماعي حول **(IQR) الاتجاه المركزي ونطاق الربيعي** (Q₁) إلى 6.2 ساعات (Q₃) من حوالي 2.8 ساعة IQR 4.5 ساعات، مع نطاق (Q₃) إلى 6.2 ساعات (Q₁) من حوالي 2.8 ساعة IQR 4.5 ساعات، مع نطاق
- الانحراف الأيمن وتوزيع الذيل:** تُظهر الميزة انحرافاً أيمن ملحوظاً. بينما يصل الخط العلوي الرئيسي إلى حوالي 11.2 ساعة، يمتد ذيل متميز من القيم الشاذة من 11.2 ساعة إلى أقصى حد 14 ساعة في اليوم.

Key Findings & Statistical Trends

- Central Tendency & IQR:** The median daily social media usage sits at approximately 4.5 hours, with the Interquartile Range (IQR) spanning from around 2.8 hours (Q_1) to 6.2 hours (Q_3).
- Right Skewness & Tail Distribution:** The feature exhibits a noticeable right (positive) skew. While the main upper whisker reaches up to roughly 11.2 hours, a distinct tail of outliers extends from 11.2 hours up to a maximum of 14 hours per day.

الرؤى المستخلصة من البيانات

- تخصيص الوقت اليومي الكبير:** ينفق أكثر من نصف الطلاب المستطلعين أكثر من 4.5 ساعات يومياً على منصات وسائل التواصل الاجتماعي.
- مخاطر الاستخدام القصوى:** تشير مجموعة القيم الشاذة القصوى إلى مجموعة صغيرة من المستخدمين الفائقي الانخراط. في الدراسات الأكاديمية، يرتبط هذا المستوى العالي من وقت الشاشة بشكل متكرر مع حرمان النوم والمشاركة الدراسية المنخفضة.

Data Insights

- Substantial Daily Time Allocation:** Over half of the surveyed students spend more than 4.5 hours daily on social media platforms, representing a major allocation of non-academic discretionary time.
- Extreme Usage Risks:** The cluster of extreme outliers (up to 14 hours) points to a small subset of hyper-engaged users. In academic studies, such high levels of screen time often correlate with sleep deprivation, reduced study engagement, and heightened vulnerability to mental distress.

الخطوات العملية القابلة للتنفيذ

- مقابل Daily_Social_Media_Hours الارتباط عبر الميزات: تفحص متبادل لـ Academic_Performance_Score وقياس الإرهاق.
- تحجيم الميزات والتحويل: تطبيق التحجيم القوي أو تحويل السجل لتطبيع القيم الشاذة في الطرف الأيمن.

Actionable Takeaways

- **Cross-Feature Correlation:** Cross-examine `Daily_Social_Media_Hours` against `Academic_Performance_Score` and burnout metrics to identify threshold effects where social media consumption begins negatively impacting grades.
- **Feature Scaling & Transformation:** Apply robust scaling or log transformation to normalize the right-tail outliers before using this feature in linear regression models.

```
In [23]: # إنشاء رسم الصندوق لساعات وسائل التواصل الاجتماعي اليومية
# Create box plot for Daily Social Media Hours
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, y='Daily_Social_Media_Hours', ax=ax, palette='coolwarm')
ax.set_title('توزيع ساعات وسائل التواصل الاجتماعي اليومية\nDistribution of Daily Social Media Hours')
ax.set_ylabel('الساعات في اليوم / Hours per day', fontsize=12)
ax.grid(axis='y', alpha=0.3)

# إضافة التعليقات الإحصائية
# Add statistical annotations
q1_sm = df['Daily_Social_Media_Hours'].quantile(0.25)
q3_sm = df['Daily_Social_Media_Hours'].quantile(0.75)
median_sm = df['Daily_Social_Media_Hours'].median()
iqr_sm = q3_sm - q1_sm

stats_text = f'الوسيط / Median: {median_sm:.2f}\nQ1: {q1_sm:.2f}\nQ3: {q3_sm:.2f}\nIQR: {iqr_sm:.2f}'
ax.text(0.98, 0.97, stats_text, transform=ax.transAxes,
       fontsize=10, verticalalignment='top', horizontalalignment='right',
       bbox=dict(boxstyle='round', facecolor='lightyellow', alpha=0.5))


plt.tight_layout()
plt.savefig('../reports/figures/boxplot_Daily_Social_Media_Hours.png', dpi=300,
plt.show())

print('إحصائيات استخدام وسائل التواصل الاجتماعي اليومية / Daily Social Media Usage Statistics')
print(f'المتوسط / Mean: {df["Daily_Social_Media_Hours"].mean():.2f}')
print(f'الوسيط / Median: {median_sm:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Daily_Social_Media_Hours"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Daily_Social_Media_Hours"].min():.2f}')
print(f'الحد الأقصى / Max: {df["Daily_Social_Media_Hours"].max():.2f}')
```

C:\Users\ayman\AppData\Local\Temp\ipykernel_23652\3796913891.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df, y='Daily_Social_Media_Hours', ax=ax, palette='coolwarm')
```



Daily Social Media Usage Statistics: / إحصائيات استخدام وسائل التواصل الاجتماعي اليومية

المتوسط / Mean: 4.54
الوسيط / Median: 4.50
الانحراف المعياري / Std Dev: 2.40
الحد الأدنى / Min: 0.00
الحد الأقصى / Max: 14.00

القسم 4: الصحة النفسية والرفاهية

Section 4: Mental Health & Wellbeing

رسم الصندوق لدرجة الصحة النفسية

Box Plot of Mental Health Score

نظرة عامة على الشكل يلخص رسم الصندوق هذا الاتجاه المركزي والتشتت وحضور القيم الشاذة في الطرف السفلي لمتغير درجة الصحة النفسية عبر السكان المستطلعين من الطلاب.

Figure Overview This box plot summarizes the central tendency, dispersion, and lower-tail outlier presence for the continuous variable `Mental_Health_Score` across the surveyed student population.

الاتجاهات الإحصائية الرئيسية والنتائج

- من IQR يقع الدرجة الوسيطة حول 73.5، مع نطاق (IQR) الاتجاه المركزي ونطاق الربيعي (Q₃) 79.5 إلى (Q₁) 79.5 حوالي 67.0.
- الانحراف الأيسر المعتدل وحضور الطرف السفلي: يُظهر التوزيع انحرافاً يساراً لطيفاً. يصل الخط العلوي إلى حد أقصى بالقرب من 85، بينما ينخفض الخط السفلي إلى حوالي 53، مع مجموعة مرئية من القيم الشاذة.

Key Findings & Statistical Trends

- **Central Tendency & IQR:** The median score sits at approximately 73.5, with the Interquartile Range (IQR) spanning from around 67.0 (Q_1) to 79.5 (Q_3).
- **Slight Left Skew & Moderate Lower-Tail Presence:** The distribution exhibits a gentle leftward (negative) skew. The upper whisker reaches a maximum near 85, while the lower whisker descends to approximately 53, with a visible cluster of mental health risk outliers extending down to as low as 38.

الرؤى المستخلصة من البيانات

- **خط الأساس الصحة النفسية المعتدل:** يشير الوسيط حول 73.5 إلى أن معظم الطلاب يُبلغون عن رفاهية نفسية معتدلة إلى جيدة.
- **مخاطر المجموعة الفرعية الضعيفة:** تسلط 15+ القيم الشاذة في النطاق 38-60 الضوء على الأقلية الضعيفة التي تعاني من الضائقة النفسية الشديدة.

Data Insights

- **Moderate Baseline Mental Health:** The median around 73.5 suggests that most students report moderate-to-good mental wellness, without widespread acute distress.
- **Vulnerable Subgroup Risk:** The 15+ outliers in the 38–60 range highlight a vulnerable minority experiencing severe psychological distress, warranting targeted mental health interventions and counseling support.

الخطوات العملية القابلة للتنفيذ

- **وضع علامات على مخاطر الصحة النفسية:** إنشاء تنبيهات آلية للطلاب الذين يسجلون درجات صحة نفسية تحت 55.
- **تحليل الارتباط مع الأداء الأكاديمي:** ربط درجات الصحة النفسية المنخفضة مع الدرجات المنخفضة والمستويات العالية من الإجهاد.

Actionable Takeaways

- **Mental Health Risk Flagging:** Establish automated alerts for students with Mental_Health_Scores below 55 to trigger urgent referrals to campus counseling services.
- **Correlation Analysis with Academic Performance:** Cross-reference low mental health scores against failing grades and high stress levels to establish predictive thresholds for intervention timing.

In [24]:

```
# إنشاء رسم الصندوق لدرجة الصحة النفسية
# Create box plot for Mental Health Score
fig, ax = plt.subplots(figsize=(10, 6))

sns.boxplot(data=df, y='Mental_Health_Score', ax=ax, palette='RdYlGn')
ax.set_title('توزيع درجة الصحة النفسية\nDistribution of Mental Health Score',
ax.set_ylabel('الدرجة / Score (0-100)', fontsize=12)
ax.grid(axis='y', alpha=0.3)

# إضافة التعليقات الإحصائية
```

```
# Add statistical annotations
q1_mh = df['Mental_Health_Score'].quantile(0.25)
q3_mh = df['Mental_Health_Score'].quantile(0.75)
median_mh = df['Mental_Health_Score'].median()
iqr_mh = q3_mh - q1_mh

stats_text = f'الوسيط / Median: {median_mh:.2f}\\nQ1: {q1_mh:.2f}\\nQ3: {q3_mh:.2f}\\nIQR: {iqr_mh:.2f}'
ax.text(0.98, 0.97, stats_text, transform=ax.transAxes,
        fontsize=10, verticalalignment='top', horizontalalignment='right',
        bbox=dict(boxstyle='round', facecolor='lightcoral', alpha=0.5))


plt.tight_layout()
plt.savefig('../reports/figures/boxplot_Mental_Health_Score.png', dpi=300, bbox_inches='tight')
plt.show()

print('إحصائيات درجة الصحة النفسية / Mental Health Score Statistics:')
print(f'المتوسط / Mean: {df["Mental_Health_Score"].mean():.2f}')
print(f'الوسيط / Median: {median_mh:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Mental_Health_Score"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Mental_Health_Score"].min():.2f}')
print(f'الحد الأقصى / Max: {df["Mental_Health_Score"].max():.2f}')
```

C:\Users\ayman\AppData\Local\Temp\ipykernel_23652\454955376.py:5: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.boxplot(data=df, y='Mental_Health_Score', ax=ax, palette='RdYlGn')
```



إحصائيات درجة الصحة النفسية / Mental Health Score Statistics:
المتوسط / Mean: 72.51
الوسيط / Median: 73.76
الانحراف المعياري / Std Dev: 9.25
الحد الأدنى / Min: 32.56
الحد الأقصى / Max: 91.76

القسم 5: مقاييس نمط الحياة والصحة

Section 5: Lifestyle & Health Metrics

توزيع ساعات النوم

Distribution of Sleep Hours

التوزيع (KDE) نظرة عامة على الشكل يعرض هذا الرسم البياني للتكرار مع منحني تقدير كثافة النواة المستمر والاتجاه المركزي والانتشار المتمثل لساعات النوم عبر السكان من الطلاب.

Figure Overview This histogram overlaid with a Kernel Density Estimation (KDE) curve presents the continuous frequency distribution, central tendency, and symmetric spread for Sleep_Hours across the student population.

الاتجاهات الإحصائية الرئيسية والنتائج

- التوزيع المتمثل الغاوسي:** يُظهر المتغير توزيعاً على شكل جرس (طبيعي) كلاسيكي متمركزاً حول متوسط/وسيط حوالي 6.5 إلى 6.8 ساعة.
- الانتشار المتوازن للطرف:** يمتد التوزيع بشكل متمثل من الحد الأدنى بالقرب من 2.0 ساعة إلى الحد الأقصى حول 11.0 ساعات.

Key Findings & Statistical Trends

- Symmetric Gaussian Distribution:** The variable exhibits a classic bell-shaped (normal) distribution centered around a mean/median of approximately 6.5 to 6.8 hours, reaching a peak bin count of roughly 660 students.
- Balanced Tail Spread:** The distribution spans symmetrically from a lower tail minimum near 2.0 hours to an upper tail maximum around 11.0 hours, with the vast majority of students logging between 5.0 and 8.5 hours.

الرؤى المستخلصة من البيانات

- نظافة النوم النمذجية:** يحتفظ معظم الطلاب بأنماط نوم يومية واقعية متجمعة بالقرب من الإرشادات الموصى بها (6-8 ساعات).
- أجزاء الذيل القصوى:** يمثل الأفراد المحرومون من النوم جداً (> 4.0 ساعات) والقيم الشاذة العالية (< 9.5 ساعات) مجموعات فرعية صغيرة قد ترتبط بالإجهاد الأكاديمي القصوي.

Data Insights

- Typical Sleep Hygiene:** Most students maintain realistic daily sleep patterns clustering close to recommended guidelines (6–8 hours).
- Extreme Tail Segments:** Both sleep-deprived individuals (< 4.0 hours) and high-sleep outliers (> 9.5 hours) represent small, symmetric subgroups that may correlate with extreme academic stress or underlying health conditions.

الخطوات العملية القابلة للتنفيذ

- بشكل طبيعي، يمكن تطبيق التطبيق Sleep_Hours توافق التحجيم القياسي: منذ أن يتم توزيع القياسي مباشرة.

- **مراقبة حرمان النوم:** وضع علامات على الطلاب الذين يُبلغون عن أقل من 4.5 ساعات من النوم كأهداف محتملة.

Actionable Takeaways

- **Standard Scaling Compatibility:** Since `Sleep_Hours` is normally distributed, standard normalization/Z-score standardization (`StandardScaler`) can be directly applied without needing logarithmic transformations.
- **Sleep Deprivation Monitoring:** Flag students reporting under 4.5 hours of sleep as potential targets for wellness interventions and academic risk assessment.

```
In [25]: # لساعات النوم KDE إنشاء رسم بياني للتكرار مع
# Create histogram with KDE for Sleep Hours
fig, ax = plt.subplots(figsize=(12, 6))


df['Sleep_Hours'].hist(bins=30, density=True, alpha=0.6, color='skyblue', ax=ax,
df['Sleep_Hours'].plot(kind='density', ax=ax, color='red', linewidth=2.5, label=

ax.set_title('توزيع ساعات النوم\nDistribution of Sleep Hours', fontsize=14, for
ax.set_xlabel('الساعات في الليل / Hours per night', fontsize=12)
ax.set_ylabel('الكثافة / Density', fontsize=12)
ax.legend()
ax.grid(alpha=0.3)

# إضافة خطوط المتوسط والوسيط
# Add mean and median lines
mean_sleep = df['Sleep_Hours'].mean()
median_sleep = df['Sleep_Hours'].median()
ax.axvline(mean_sleep, color='green', linestyle='--', linewidth=2, label=f'متوسط'
ax.axvline(median_sleep, color='orange', linestyle='--', linewidth=2, label=f'يط
ax.legend()

plt.tight_layout()
plt.savefig('../reports/figures/distribution_Sleep_Hours.png', dpi=300, bbox_inc
plt.show()

print('إحصائيات ساعات النوم / Sleep Hours Statistics:')
print(f' المتوسط / Mean: {mean_sleep:.2f}')
print(f' الوسيط / Median: {median_sleep:.2f}')
print(f' الانحراف المعياري / Std Dev: {df["Sleep_Hours"].std():.2f}')
print(f' الحد الأدنى / Min: {df["Sleep_Hours"].min():.2f}')
print(f' الحد الأقصى / Max: {df["Sleep_Hours"].max():.2f}')
```



إحصائيات ساعات النوم / Sleep Hours Statistics:

المتوسط / Mean: 6.54

الوسيط / Median: 6.55

الانحراف المعياري / Std Dev: 1.27

الحد الأدنى / Min: 2.00

الحد الأقصى / Max: 11.15

توزيع ساعات النشاط البدني

Distribution of Physical Activity Hours

التوزيع المستمر وقمة KDE نظرة عامة على الشكل يوضح هذا الرسم البياني للتكرار مع منحني الصفر والتسوس الأيمن لساعات النشاط البدني عبر مجموعة الطلاب.

Figure Overview This histogram overlaid with a Kernel Density Estimation (KDE) curve illustrates the continuous frequency distribution, zero-inflation spike, and right-tail decay for `Physical_Activity_Hours` across the student cohort.

الاتجاهات الإحصائية الرئيسية والنتائج

- قمة الصفر:** تظهر قمة مهيمنة بالضبط عند 0.0 ساعة، وتلتقط أكثر من 3100 طالب يُبلغون عن نشاط بدني يومي صفري.
- الانتشار الثانوي الأحادي والانحراف الأيمن:** بالنسبة للأفراد النشطين، يشكل التوزيع قمة عريضة متمركزة بين 0.8 و 1.5 ساعة يومياً.

Key Findings & Statistical Trends

- Zero-Inflation Spike:** A dominant spike appears at exactly 0.0 hours, capturing over 3,100 students who report zero daily physical activity.
- Unimodal Secondary Spread & Right Skew:** For active individuals, the distribution forms a broad peak centered between 0.8 and 1.5 hours daily before tapering off in a right-skewed tail up to a maximum of 5.0 hours.

الرؤى المستخلصة من البيانات

- **نسبة عالية من الخمول:** يسجل أكثر من 20% من السكان المستطلعين نشاطاً بدنياً يومياً صفرياً.
- **الانخراط المنخفض متوسط:** حتى بين الطلاب النشطين، يبقى النشاط البدني اليومي متواضعاً نسبياً.

Data Insights

- **High Sedentary Proportion:** Over 20% of the surveyed population logs no daily physical activity, presenting a widespread sedentary lifestyle baseline across the cohort.
- **Low Average Engagement:** Even among active students, daily activity remains relatively modest, with very few logging more than 3.0 hours.

الخطوات العملية القابلة للتنفيذ

- **هندسة الميزات الثنائية:** إنشاء متغير مؤشر مخصص (Is_Physically_Active: 0 1 مقابل).
- **تحويل السجل:** تطبيق تحويل السجل (x + 1) أو استخدام خوارزميات قائمة على الأشجار (x + 1) **تحويل السجل:** تطبيق تحويل السجل (x + 1) أو استخدام خوارزميات قائمة على الأشجار (x + 1)

Actionable Takeaways

- **Binary Feature Engineering:** Create a dedicated indicator variable (Is_Physically_Active : 0 vs. 1) to model structural differences between non-active and active students.
- **Distribution Scaling:** Apply a $\log(x + 1)$ transformation or utilize tree-based algorithms to effectively manage the heavy zero mass and positive skew.

```
In [26]: # لساعات النشاط البدني KDE إنشاء رسم بياني للتكرار مع
# Create histogram with KDE for Physical Activity Hours
fig, ax = plt.subplots(figsize=(12, 6))

df['Physical_Activity_Hours'].hist(bins=30, density=True, alpha=0.6, color='lightcoral')
df['Physical_Activity_Hours'].plot(kind='density', ax=ax, color='darkred', linewidth=2)


ax.set_title('توزيع ساعات النشاط البدني\nDistribution of Physical Activity Hours')
ax.set_xlabel('الساعات في اليوم / Hours per day', fontsize=12)
ax.set_ylabel('الكثافة / Density', fontsize=12)
ax.legend()
ax.grid(alpha=0.3)

# إضافة خطوط المتوسط والوسيط
# Add mean and median lines
mean_activity = df['Physical_Activity_Hours'].mean()
median_activity = df['Physical_Activity_Hours'].median()
ax.axvline(mean_activity, color='blue', linestyle='--', linewidth=2, label=f'المتوسط')
ax.axvline(median_activity, color='purple', linestyle='--', linewidth=2, label=f'الوسيط')
ax.legend()

plt.tight_layout()
plt.savefig('../reports/figures/distribution_Physical_Activity_Hours.png', dpi=300)
plt.show()

print('إحصائيات ساعات النشاط البدني / Physical Activity Hours Statistics:')
```

```
print(f' المتوسط / Mean: {mean_activity:.2f}')
print(f' الوسيط / Median: {median_activity:.2f}')
print(f' الانحراف المعياري / Std Dev: {df["Physical_Activity_Hours"].std():.2f}')
print(f' الحد الأدنى / Min: {df["Physical_Activity_Hours"].min():.2f}')
print(f' الحد الأقصى / Max: {df["Physical_Activity_Hours"].max():.2f}')
```



إحصائيات ساعات النشاط البدني / Physical Activity Hours Statistics:

المتوسط / Mean: 1.25

الوسيط / Median: 1.13

الانحراف المعياري / Std Dev: 1.04

الحد الأدنى / Min: 0.00

الحد الأقصى / Max: 5.00

توزيع درجة العزلة الاجتماعية

Distribution of Social Isolation Score

التوزيع المستمر والاتجاه KDE نظرة عامة على الشكل يعرض هذا الرسم البياني للتكرار مع منحنى المركزي والانتشار المتمثل لدرجة العزلة الاجتماعية عبر السكان المستطلعين من الطلاب.

Figure Overview This histogram overlaid with a Kernel Density Estimation (KDE) curve presents the continuous frequency distribution, central tendency, and symmetric spread for `Social_Isolation_Score` across the surveyed student population.

الاتجاهات الإحصائية الرئيسية والنتائج

- التوزيع المتمثل الغاوسي: يُظهر المقياس ملف تعريف على شكل جرس (طبيعي) كلاسيكي متمركزاً حول متوسط حوالي 4.2.
- الانتشار المتوازن عبر النطاق: تمتد الدرجات بشكل متمثل من الحد الأدنى بالقرب من 1.0 إلى الحد الأقصى حول 8.0.

Key Findings & Statistical Trends

- Symmetric Gaussian Distribution:** The metric exhibits a classic bell-shaped (normal) profile centered around a mean of approximately 4.2, peaking at nearly 680 students per bin.

- **Balanced Spread Across Range:** The scores span symmetrically from a lower bound near 1.0 to an upper tail maximum around 8.0, with the vast majority of students scoring between 2.5 and 6.0.

الرؤى المستخلصة من البيانات

- **خط الأساس الاعتدالي الشامل:** يعاني معظم الطلاب من مستويات معتدلة من العزلة الاجتماعية.
- **الأطراف المتماثلة:** يشكل الطلاب الذين لا يشعرون بعزلة تقريباً والذين يعانون من عزلة شديدة جزءاً متساوياً ومتماثلاً من الذيل.

Data Insights

- **Moderate Overall Baseline:** Most students experience moderate levels of social isolation, clustering safely away from the extreme high end of the scale.
- **Symmetric Extremes:** Students feeling virtually no isolation (*le2.0*) and those experiencing severe isolation (*ge6.5*) form equal, symmetric tail segments, making isolation risk an even-spectrum factor across the cohort.

الخطوات العملية القابلة للتنفيذ

- **(StandardScaler / تحويل Z-score) المعالجة المسبقة القياسية:** تطبيق التطبيع القياسي مباشرة.
- **حد تدخل العزلة العالي:** تعيين علامة آلية للطلاب الذين يسجلون درجة عزلة اجتماعية أعلى من 6.0.

Actionable Takeaways

- **Standard Preprocessing:** Apply standard normalization (`StandardScaler` / Z-score transformation) directly, as the feature adheres to a normal distribution without requiring non-linear transforms.
- **High-Isolation Intervention Threshold:** Set an automated flag for students recording a `Social_Isolation_Score` above 6.0 to trigger wellness check-ins and community integration programs.

```
In [27]: # لدرجة العزلة الاجتماعية KDE إنشاء رسم بياني للتكرار مع
# Create histogram with KDE for Social Isolation Score
fig, ax = plt.subplots(figsize=(12, 6))

df['Social_Isolation_Score'].hist(bins=30, density=True, alpha=0.6, color='plum')
df['Social_Isolation_Score'].plot(kind='density', ax=ax, color='purple', linewidth=2)

ax.set_title('توزيع درجة العزلة الاجتماعية\nDistribution of Social Isolation Score')
ax.set_xlabel('الدرجة / Score (0-10)', fontsize=12)
ax.set_ylabel('الكثافة / Density', fontsize=12)
ax.legend()
ax.grid(alpha=0.3)

# إضافة خطوط المتوسط والوسيط
# Add mean and median lines
```


```

mean_isolation = df['Social_Isolation_Score'].mean()
median_isolation = df['Social_Isolation_Score'].median()
ax.axvline(mean_isolation, color='navy', linestyle='--', linewidth=2, label=f'سطح المتوسط')
ax.axvline(median_isolation, color='teal', linestyle='--', linewidth=2, label=f'سطح الوسيط')
ax.legend()

plt.tight_layout()
plt.savefig('../reports/figures/distribution_Social_Isolation_Score.png', dpi=30)
plt.show()

print('إحصائيات درجة العزلة الاجتماعية / Social Isolation Score Statistics:')
print(f'المتوسط / Mean: {mean_isolation:.2f}')
print(f'الوسيط / Median: {median_isolation:.2f}')
print(f'الانحراف المعياري / Std Dev: {df["Social_Isolation_Score"].std():.2f}')
print(f'الحد الأدنى / Min: {df["Social_Isolation_Score"].min():.2f}')
print(f'الحد الأقصى / Max: {df["Social_Isolation_Score"].max():.2f}')

```



إحصائيات درجة العزلة الاجتماعية / Social Isolation Score Statistics:

المتوسط / Mean: 4.31

الوسيط / Median: 4.28

الانحراف المعياري / Std Dev: 1.16

الحد الأدنى / Min: 0.97

الحد الأقصى / Max: 8.41

الملخص والخطوات التالية

Summary & Next Steps

الوجبات الرئيسية

Key Takeaways

1. توزيع واضح ثنائي الاتجاه مع مجموعة: **الأداء الأكاديمي / Academic Performance**.
منخفضة الأداء تتطلب تدخلاً موجهًا.

2. **Academic Performance:** Clear bimodal distribution with a vulnerable low-performing cohort requiring targeted intervention.
3. **Age Demographics:** انتشار متوازن عبر المراحل التطورية / الخصائص الديموغرافية للعمر (13-25). مما يشير إلى الحاجة لتحليل مقسم حسب العمر.
4. **Age Demographics:** Balanced spread across developmental stages (13–25) suggesting need for age-stratified analysis.
5. **Technology Usage:** أدوات الذكاء الاصطناعي ووسائل التواصل / استخدام التكنولوجيا. الاجتماعي تُظهران توزيعات منحرفة لليمين مع مجموعات قيم شاذة مهمة.
6. **Technology Usage:** Both AI tools and social media show right-skewed distributions with significant outlier populations.
7. **Mental Health:** الصحة النفسية / خط أساس معتدل مع مجموعة قيم شاذة مثيرة للقلق. تستدعي إحالات الاستشارة.
8. **Mental Health:** Moderate baseline with concerning outlier cluster warranting counseling referrals.
9. **Lifestyle Factors:** عوامل نمط الحياة:
 - توزيع شبه طبيعي مع الامتثال الجيد: Sleep / النوم
 - قيم شاذة معكوسة بالصفير مع أغلبية مستقرة: Physical Activity / النشاط البدني
 - توزيع متماثل مع أطراف قابلة للإدارة: Social Isolation / العزلة الاجتماعية

التوصيات للتحليل المستقبلي

Recommendations for Future Analysis

- فحص العلاقات بين ساعات الاستخدام والنوم / مصفوفة الارتباط والأداء الأكاديمي / **Correlation Matrix:**
- **Correlation Matrix:** Examine relationships between usage hours, sleep, and academic performance
- بناء نماذج تصنيف المخاطر باستخدام السكان / النمذجة التنبؤية المعلمة / **Predictive Modeling:**
- **Predictive Modeling:** Build risk classification models using flagged populations
- تطوير برامج موجهة للمجموعات الفرعية المعرضة / تصميم التدخل للمخاطر المحددة / **Intervention Design:**
- **Intervention Design:** Develop targeted programs for identified at-risk subgroups
- تطبيق أنظمة المراقبة للمؤشرات الحمراء المبكرة / التتبع الطولي / **Longitudinal Tracking:**
- **Longitudinal Tracking:** Implement monitoring systems for early warning indicators

