

01_3 — Relationship Analysis / تحليل العلاقات

الهدف | Objective

هذا الدفتر يركز على العلاقات بين المتغيرات في بيانات الطلاب، وليس فقط توزيع كل متغير بشكل منفصل.

سنستخدم:

- لرؤية شكل العلاقة بين متغيرين Scatter Plots.
- لمقارنة المتوسطات حسب المجموعات Line Plots.
- لرؤية العلاقات الخطية بشكل عام Correlation Heatmap.
- لمقارنة المتغيرات الرقمية بين مستويات Box Plots `Burnout_Level`.

الرسومات (Causation) لا يعني السببية (Correlation) الارتباط **Important: | مهم** تساعدنا على اكتشاف الأنماط، لكنها لا تثبت أن متغيرًا يسبب الآخر.

```
In [1]: # =====
# IMPORTS
# =====

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from pathlib import Path

plt.rcParams["figure.figsize"] = (9, 5)

print("Libraries imported successfully.")
```

Libraries imported successfully.

1. تحميل البيانات | Load Dataset

نقرأ ملف البيانات المنظف من مجلد `data/raw`.

We load the cleaned dataset from the `data/raw` directory.

```
In [2]: DATA_PATH = Path("../data/raw/AI_SocialMedia_Student_Health_Dataset_clean.csv")

if not DATA_PATH.exists():
    DATA_PATH = Path("../data/raw/AI_SocialMedia_Student_Health_Dataset_clean")

if not DATA_PATH.exists():
    raise FileNotFoundError(
        "Dataset not found. Update DATA_PATH with the correct CSV path."
    )

df = pd.read_csv(DATA_PATH)
```

```
print(f"Dataset shape: {df.shape}")
display(df.head())
```

Dataset shape: (15000, 14)

	Student_ID	Age	Gender	Education_Level	Daily_Social_Media_Hours	Daily_AI_Tool_Usage_Hours
0	STU_00001	19	Male	College		5.32
1	STU_00002	16	Non-binary	High School		5.21
2	STU_00003	25	Male	University		3.61
3	STU_00004	23	Male	University		2.93
4	STU_00005	20	Non-binary	College		6.52

2. Quick Data Check | فحص سريع

نتأكد من الأعمدة وأن المتغيرات المطلوبة موجودة قبل رسم العلاقات.

We check the available columns before plotting the relationships.

```
In [3]: print("Columns:")
for col in df.columns:
    print("-", col)

numeric_df = df.select_dtypes(include=np.number)

print(f"\nNumber of numerical features: {numeric_df.shape[1]}")
```

Columns:

- Student_ID
- Age
- Gender
- Education_Level
- Daily_Social_Media_Hours
- Daily_AI_Tool_Usage_Hours
- Sleep_Hours
- Physical_Activity_Hours
- Mental_Health_Score
- Physical_Health_Score
- Social_Isolation_Score
- Burnout_Level
- Academic_Performance_Score
- Academic_Failure_Risk

Number of numerical features: 10

3. Correlation Heatmap | خريطة الارتباط

توضح هذه الخريطة قوة واتجاه العلاقة الخطية بين المتغيرات الرقمية.

كيف نقرأها؟ | How to read it

- **+1** → علاقة طردية قوية / strong positive relationship
- **0** → لا توجد علاقة خطية واضحة / little or no linear relationship
- **-1** → علاقة عكسية قوية / strong negative relationship

```
In [4]: corr = numeric_df.corr(numeric_only=True)


fig, ax = plt.subplots(figsize=(12, 10))
im = ax.imshow(corr, vmin=-1, vmax=1, cmap="coolwarm")

ax.set_xticks(range(len(corr.columns)))
ax.set_yticks(range(len(corr.columns)))
ax.set_xticklabels(corr.columns, rotation=90)
ax.set_yticklabels(corr.columns)

ax.set_title("Correlation Heatmap | خريطة الارتباط")

cbar = fig.colorbar(im, ax=ax)
cbar.set_label("Pearson Correlation (r)")

plt.tight_layout()
plt.show()
```



4. Social Media vs Academic Performance

ساعات السوشيال ميديا مقابل الأداء الأكاديمي

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [5]: x = "Daily_Social_Media_Hours"
y = "Academic_Performance_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])


    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Daily_Social_Media_Hours vs Academic_Performance_Score (Pearson r = {r:.3f})")
    ax.set_xlabel(x)
    ax.set_ylabel(y)

    plt.tight_layout()
    plt.show()

    print(f"Pearson correlation: {r:.3f}")
else:
    print("Required columns were not found.")
```



Pearson correlation: -0.394

التفسير | Interpretation

إذا كان خط الاتجاه نازلاً، فهذا يعني وجود **علاقة عكسية**: كلما زادت ساعات السوشيال ميديا، يميل الأداء الأكاديمي إلى الانخفاض.

If the trend line slopes downward, there is a **negative relationship**: higher social media usage tends to be associated with lower academic performance.

هذا لا يعني أن السوشيال ميديا تسبب انخفاض الأداء بشكل مباشر.

5. Social Media vs Mental Health

ساعات السوشيال ميديا مقابل الصحة النفسية

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [6]: x = "Daily_Social_Media_Hours"
y = "Mental_Health_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])


    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Daily_Social_Media_Hours vs Mental_Health_Score (Pearson r =
    ax.set_xlabel(x)
    ax.set_ylabel(y)

    plt.tight_layout()
    plt.show()

    print(f"Pearson correlation: {r:.3f}")
else:
    print("Required columns were not found.")
```



Pearson correlation: -0.400

التفسير | Interpretation

إذا كان الاتجاه نازلاً، فهذا يعني أن الطلاب الذين يستخدمون السوشيال ميديا لساعات أكثر يميلون أقل Mental Health إلى تسجيل درجات.

A downward trend suggests that higher social media usage is associated with lower mental health scores.

6. Social Media vs Social Isolation

ساعات السوشيال ميديا مقابل العزلة الاجتماعية

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [7]: x = "Daily_Social_Media_Hours"
y = "Social_Isolation_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])

    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Daily_Social_Media_Hours vs Social_Isolation_Score (Pearson r
    ax.set_xlabel(x)
```


```

ax.set_ylabel(y)

plt.tight_layout()
plt.show()

print(f"Pearson correlation: {r:.3f}")
else:
print("Required columns were not found.")

```



Pearson correlation: 0.439

التفسير | Interpretation

إذا كان خط الاتجاه صاعدًا، فهذا يشير إلى علاقة طردية: زيادة استخدام السوشيل ميديا ترتبط بزيادة `Social_Isolation_Score`.

An upward trend suggests a positive relationship between social media usage and social isolation.

7. Mental Health vs Academic Performance

الصحة النفسية مقابل الأداء الأكاديمي

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```

In [8]: x = "Mental_Health_Score"
        y = "Academic_Performance_Score"

        if x in df.columns and y in df.columns:
            temp = df[[x, y]].dropna()
            r = temp[x].corr(temp[y])

```

```

fig, ax = plt.subplots()
ax.scatter(temp[x], temp[y], alpha=0.25, s=18)


z = np.polyfit(temp[x], temp[y], 1)
line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

ax.set_title(f"Mental_Health_Score vs Academic_Performance_Score (Pearson r
ax.set_xlabel(x)
ax.set_ylabel(y)

plt.tight_layout()
plt.show()

print(f"Pearson correlation: {r:.3f}")
else:
print("Required columns were not found.")

```



Pearson correlation: 0.204

التفسير | Interpretation

إذا كان الاتجاه صاعدًا، فهذا يعني أن درجات الصحة النفسية الأعلى ترتبط عادةً بأداء أكاديمي أعلى.

An upward trend suggests that higher mental health scores are associated with better academic performance.

8. Physical Activity vs Mental Health

النشاط البدني مقابل الصحة النفسية

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [9]: x = "Physical_Activity_Hours"
y = "Mental_Health_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])


    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Physical_Activity_Hours vs Mental_Health_Score (Pearson r = {r:.3f})")
    ax.set_xlabel(x)
    ax.set_ylabel(y)

    plt.tight_layout()
    plt.show()

    print(f"Pearson correlation: {r:.3f}")
else:
    print("Required columns were not found.")
```



Pearson correlation: 0.246

9. Physical Activity vs Physical Health

النشاط البدني مقابل الصحة الجسدية

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [10]: x = "Physical_Activity_Hours"
y = "Physical_Health_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])


    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Physical_Activity_Hours vs Physical_Health_Score (Pearson r = 
    ax.set_xlabel(x)
    ax.set_ylabel(y)

    plt.tight_layout()
    plt.show()

    print(f"Pearson correlation: {r:.3f}")
else:
    print("Required columns were not found.")
```



Pearson correlation: 0.423

10. Sleep Hours vs Mental Health — Line Plot

ساعات النوم مقابل الصحة النفسية

لكل قيمة من قيم ساعات `Mental_Health_Score` بدل أن نعرض كل نقطة، نستخدم متوسط النوم حتى يظهر الاتجاه بشكل أوضح.

Instead of plotting every individual observation, we plot the average mental health score for each sleep-hour value.


```
In [11]: x = "Sleep_Hours"
y = "Mental_Health_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna().copy()
    grouped = temp.groupby(x, as_index=False)[y].mean()

    fig, ax = plt.subplots()
    ax.plot(grouped[x], grouped[y], marker="o")

    ax.set_title(
        "Average Mental Health by Sleep Hours | "
        "متوسط الصحة النفسية حسب ساعات النوم"
    )
    ax.set_xlabel("Sleep Hours")
    ax.set_ylabel("Average Mental Health Score")

    plt.tight_layout()
    plt.show()
```



التفسير | Interpretation

راقب شكل الخط: هل ترتفع الصحة النفسية مع النوم؟ وهل يوجد نطاق معين من ساعات النوم يعطي متوسطًا أفضل؟

The line helps us see whether mental health tends to change across different sleep durations.

11. Burnout Level vs Academic Performance

مستوى الاحتراق النفسي مقابل الأداء الأكاديمي

مناسب لمقارنة الأداء الأكاديمي بين Box Plot متغير فئوي، فإن Burnout_Level لأن

Low → Moderate → High → Severe

Because `Burnout_Level` is categorical, a Box Plot is useful for comparing academic performance across burnout levels.

```
In [12]: x = "Burnout_Level"
y = "Academic_Performance_Score"

if x in df.columns and y in df.columns:
    order = ["Low", "Moderate", "High", "Severe"]

    groups = [
        df.loc[df[x] == level, y].dropna()
        for level in order
    ]


    labels = [
        level for level, values in zip(order, groups)
        if len(values) > 0
    ]

    groups = [
        values for values in groups
        if len(values) > 0
    ]

    fig, ax = plt.subplots()
    ax.boxplot(groups, tick_labels=labels)

    ax.set_title(
        "Academic Performance by Burnout Level | "
        "Burnout الأداء الأكاديمي حسب مستوى"
    )
    ax.set_xlabel("Burnout_Level")
    ax.set_ylabel("Academic_Performance_Score")

    plt.tight_layout()
    plt.show()
```



التفسير | Interpretation

فهذا يشير إلى وجود Burnout، الأداء الأكاديمي ينخفض كلما ارتفع مستوى الـ Median إذا لاحظنا أن وانخفاض الأداء الأكاديمي Burnout علاقة بين ارتفاع الـ

If the median academic performance decreases as burnout severity increases, this suggests an association between higher burnout and lower academic performance.

12. Burnout Level vs Mental Health

مستوى الاحتراق النفسي مقابل الصحة النفسية

```
In [13]: x = "Burnout_Level"
y = "Mental_Health_Score"

if x in df.columns and y in df.columns:
    order = ["Low", "Moderate", "High", "Severe"]

    groups = [
        df.loc[df[x] == level, y].dropna()
        for level in order
    ]


    labels = [
        level for level, values in zip(order, groups)
        if len(values) > 0
    ]

    groups = [
        values for values in groups
        if len(values) > 0
    ]

    fig, ax = plt.subplots()
    ax.boxplot(groups, tick_labels=labels)

    ax.set_title(
        "Mental Health by Burnout Level | "
        "Burnout الصحة النفسية حسب مستوى"
    )
    ax.set_xlabel("Burnout_Level")
    ax.set_ylabel("Mental_Health_Score")

    plt.tight_layout()
    plt.show()
```



التفسير | Interpretation

فهذا يدل على Severe، إلى Low مع الانتقال من `Mental_Health_Score` إذا انخفضت درجات وانخفاض الصحة النفسية Burnout وجود ارتباط بين ارتفاع مستوى الـ.

If mental health scores decrease from Low to Severe burnout, this indicates an association between burnout severity and mental health.

13. Social Media vs Academic Failure Risk

ساعات السوشيال ميديا مقابل خطر الفشل الأكاديمي

متغير ثنائي `Academic_Failure_Risk`:

- `0` = غير معرض للخطر
- `1` = معرض للخطر

سنقارن متوسط ساعات السوشيال ميديا بين المجموعتين.

```
In [14]: x = "Academic_Failure_Risk"
y = "Daily_Social_Media_Hours"

if x in df.columns and y in df.columns:
    grouped = df.groupby(x)[y].mean()


    fig, ax = plt.subplots()
    ax.plot(
        grouped.index.astype(str),
        grouped.values,
        marker="o"
    )

    ax.set_title(
        "Average Social Media Hours by Academic Failure Risk"
    )
```

```
ax.set_xlabel(
    "Academic Failure Risk (0 = No, 1 = Yes)"
)
ax.set_ylabel(
    "Average Daily Social Media Hours"
)

plt.tight_layout()
plt.show()

display(grouped.rename("Average Social Media Hours"))
```



```
Academic_Failure_Risk
0    4.337782
1    7.666422
Name: Average Social Media Hours, dtype: float64
```

التفسير | Interpretation

إذا كان متوسط استخدام السوشيال ميديا أعلى لدى المجموعة 1 ، فهذا يعني أن الطلاب المصنفين كمعرضين لخطر الفشل لديهم استخدام أعلى في المتوسط.

If group 1 has higher average social media usage, students classified as at risk show higher usage on average.

لكن هذا لا يثبت السببية.

14. AI Tool Usage vs Academic Performance

استخدام أدوات الذكاء الاصطناعي مقابل الأداء الأكاديمي

لرؤية شكل العلاقة بين المتغيرين، ونضيف خط اتجاه للمساعدة في فهم Scatter Plot نستخدم الاتجاه العام.

We use a Scatter Plot to visualize the relationship and add a trend line to make the overall direction easier to see.

```
In [15]: x = "Daily_AI_Tool_Usage_Hours"
y = "Academic_Performance_Score"

if x in df.columns and y in df.columns:
    temp = df[[x, y]].dropna()
    r = temp[x].corr(temp[y])


    fig, ax = plt.subplots()
    ax.scatter(temp[x], temp[y], alpha=0.25, s=18)

    z = np.polyfit(temp[x], temp[y], 1)
    line_x = np.linspace(temp[x].min(), temp[x].max(), 100)
    ax.plot(line_x, np.polyval(z, line_x), linewidth=2)

    ax.set_title(f"Daily_AI_Tool_Usage_Hours vs Academic_Performance_Score (Pearson r = {r:.3f})")
    ax.set_xlabel(x)
    ax.set_ylabel(y)

    plt.tight_layout()
    plt.show()

    print(f"Pearson correlation: {r:.3f}")
else:
    print("Required columns were not found.")
```



Pearson correlation: -0.205

Interpretation | التفسير

مرتبطة بالأداء الأكاديمي، وهل AI هذا الرسم يساعدنا على معرفة هل ساعات استخدام أدوات العلاقة تبدو إيجابية أو سلبية أو غير واضحة.

This plot helps us examine whether AI tool usage is associated with academic performance and whether the relationship appears positive, negative, or weak.

15. Relationship Summary | ملخص العلاقات

للعلاقات المهمة في المشروع Pearson correlation في النهاية نحسب

We summarize the Pearson correlation for the main relationships.

```
In [16]: important_pairs = [
    ("Daily_Social_Media_Hours", "Academic_Performance_Score"),
    ("Daily_Social_Media_Hours", "Mental_Health_Score"),
    ("Daily_Social_Media_Hours", "Social_Isolation_Score"),
    ("Mental_Health_Score", "Academic_Performance_Score"),
    ("Physical_Activity_Hours", "Mental_Health_Score"),
    ("Physical_Activity_Hours", "Physical_Health_Score"),
    ("Sleep_Hours", "Mental_Health_Score"),
    ("Daily_AI_Tool_Usage_Hours", "Academic_Performance_Score"),
]

rows = []

for a, b in important_pairs:
    if a in df.columns and b in df.columns:
        rows.append({
            "Feature 1": a,
            "Feature 2": b,
            "Pearson r": df[a].corr(df[b])
        })

relationship_summary = (
    pd.DataFrame(rows)
    .sort_values(
        "Pearson r",
        key=lambda s: s.abs(),
        ascending=False
    )
    .reset_index(drop=True)
)

display(relationship_summary)
```

	Feature 1	Feature 2	Pearson r
0	Daily_Social_Media_Hours	Social_Isolation_Score	0.438550
1	Physical_Activity_Hours	Physical_Health_Score	0.422584
2	Daily_Social_Media_Hours	Mental_Health_Score	-0.399802
3	Daily_Social_Media_Hours	Academic_Performance_Score	-0.393920
4	Sleep_Hours	Mental_Health_Score	0.310587
5	Physical_Activity_Hours	Mental_Health_Score	0.245876
6	Daily_AI_Tool_Usage_Hours	Academic_Performance_Score	-0.205065
7	Mental_Health_Score	Academic_Performance_Score	0.204037

Final Takeaway | الخلاصة النهائية

"هذا الدفتر يحول التحليل من مجرد "كيف تتوزع البيانات؟" إلى "كيف ترتبط المتغيرات مع بعضها؟"

The notebook moves from simply asking "**How are the variables distributed?**" to asking "**How are the variables related to each other?**"

أهم العلاقات التي تستحق المتابعة في المشروع

1. Social Media Usage ↔ Academic Performance
2. Social Media Usage ↔ Mental Health
3. Social Media Usage ↔ Social Isolation
4. Mental Health ↔ Academic Performance
5. Physical Activity ↔ Mental & Physical Health
6. Sleep ↔ Mental Health
7. Burnout Level ↔ Academic Performance
8. Burnout Level ↔ Mental Health
9. AI Tool Usage ↔ Academic Performance

Important: Correlation describes association, not causation. أي علاقة تظهر هنا تحتاج إلى تحليل إحصائي أو نماذج إضافية قبل استنتاج السبب والنتيجة.